

DATA TRANSFIGURATION: INFORME TÉCNICO: IMPLEMENTACIÓN DE ARQUITECTURA MEDALLION EN LAKEHOUSE


Carlos Pazmiño Zambrano
Desarrollo de Software



CONTEXTO EJECUTIVO Y SITUACIÓN ACTUAL

Antecedentes del Proyecto

Objetivo Principal: Crear un modelo semántico analítico para el seguimiento de transacciones financieras y no financieras a nivel nacional, con capacidad de reporting en tiempo quasi-real.



Restricción Crítica:

- Bloqueo de Créditos Azure: Imposibilidad de utilizar servicios Azure Data Factory, Synapse Analytics.
- Migración Forzosa: Transición completa a stack AWS manteniendo arquitectura Lakehouse.
- Preservación de Metodología: Aplicación de patrones Medallion independientemente del proveedor cloud.

ARQUITECTURA IMPLEMENTADA

1. Capa Bronze (Raw Data)

Fuentes de Datos Originales:

- catalogo_agencias.csv Dimensiones de agencias
- catalogo_tipo_transaccion.csv Catálogo de tipos
- transacciones.csv Hechos transaccionales

Almacenamiento: Amazon S3

Formato: CSV crudo


2. Capa Silver (Cleaned & Enriched)

Procesamiento Realizado:

Tablas Resultantes:

transacciones_full Datos transaccionales enriquecidos

Estructura normalizada y lista para agregaciones



3. Capa Gold (Business Ready)

Modelo Semántico Final: transaccionalidad

Métricas Calculadas:

Campos Disponibles para Power BI:

- fecha, nombre_agencia, latitud, longitud
- tipo_trx_desc, canal_id
- cantidad_transacciones, total_monto



TECNOLOGÍAS UTILIZADAS

Cloud Provider: AWS

- S3: Almacenamiento object storage
- IAM: Gestión de credenciales seguro
- Región: us-east-2

Processing Engine: Apache Spark

- Lenguaje: Python/PySpark
- Optimizaciones: Broadcast joins para dimensiones pequeñas
- Transformaciones: SQL + DataFrame API

- ```
Pipeline implementado
```
1. Lectura desde S3 → DataFrames Pandas
  2. Conversión a Spark DataFrames
  3. Limpieza y normalización
  4. Joins semánticos
  5. Agregaciones business-ready
  6. Persistencia en tablas queryable



# ANÁLISIS DE VALOR AÑADIDO

## 1. Flexibilidad Arquitectónica

- Demostrada capacidad de adaptación entre cloud providers
- Pipeline portable entre Azure Fabric y AWS

## 2. Escalabilidad

- Procesamiento distribuido con Spark
- Capacidad de manejar crecimiento volumétrico

## 3. Gobernanza

- Metadatos preservados durante transformaciones
- Trazabilidad completa de datos

## 4. Performance

- Optimizaciones aplicadas (broadcast joins).
- Agregaciones pre-calculadas para reporting ágil.

## ARQUITECTURA DE DATOS

(Pipeline Analítico BI)



### CAPA BRONZE

#### Datos Crudos (RAW)

- CSV sin procesar
- Catalogos
- Datos históricos sin alterar

#### Objetivo

- Preservar la información original
- Fuente única de verdad inicial (raw layer)



### CAPA SILVER

#### Procesos con Spark

- Limpieza de datos
- Eliminación de errores y duplicados
- Enriquecimiento de atributos

#### Objetivo

- Transformar datos para análisis
- Estandarizar formatos



### CAPA GOLD

#### Modelo Semántico

- Agregaciones por negocio
- Cálculo de métricas clave (KPIs)
- Tablas finales optimizadas

#### Objetivo

- Preparar datos listos para consumo BI
- Alinear definiciones con negocio

## tabla de transacción

| col_name         | data_type     | comment |
|------------------|---------------|---------|
| fecha            | date          |         |
| nombre_agencia   | string        |         |
| latitud          | decimal(9,6)  |         |
| longitud         | decimal(9,6)  |         |
| tipo_trx_desc    | string        |         |
| canal_id         | bigint        |         |
| cantidad_transa- | decimal(15,2) |         |
| total_monto      | decimal       |         |

## **Alcance y Limitaciones**

**Cobertura Geográfica:** 12 agencias a nivel nacional  
(Quito, Guayaquil, Cuenca, Santo Domingo, Machala,  
Loja, Ambato, Manta, Esmeraldas, Riobamba, Ibarra,  
Tulcán)

**Período Temporal:** Datos desde marzo 2025 con  
proyección de crecimiento histórico

# RESULTADOS ALCANZADOS

- **Calidad de Datos Lograda:**
- **Integridad:** 0 valores nulos en claves principales
- **Consistencia:** Tipos de datos uniformes
- **Enriquecimiento:** Geolocalización integrada
- **Normalización:** Estructura dimensional clara

Métricas del Dataset Final:

Transacciones procesadas: Dataset completo

Agencias cubiertas: 12 ubicaciones geográficas

Tipos de transacción: Financiera/No Financiera

Canales: 4 tipos identificados